

Wealins LLM Benchmark

Veille technologique automatisée sur les modèles de langage
appliquée à l'assurance vie luxembourgeoise

Aristide Yendoulan PANGOU

Stage Wealins / Foyer Group, Luxembourg

Juin 2026

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation
- 6 Utilisation et perspectives
- 7 Conclusion

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation
- 6 Utilisation et perspectives
- 7 Conclusion

Un marché des LLM en pleine explosion

Contexte

Les modèles de langage (LLM) se multiplient à grande vitesse. Claude, GPT, Gemini, Llama, Qwen... de nouveaux modèles sortent chaque semaine.

Le problème concret

Quel LLM utiliser pour nos besoins métier ?

Impossible de les tester manuellement un par un. Les performances varient selon le domaine. Un bon modèle aujourd'hui peut être dépassé demain.


Ce dont on a besoin

Un système qui compare les LLM de façon **objective**, sur nos propres questions métier, et qui se **met à jour automatiquement** sans intervention humaine.

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation
- 6 Utilisation et perspectives
- 7 Conclusion

Vue d'ensemble du système



Collecte

70 réponses collectées
(7 LLM × 10 questions)

Évaluation

70 notations croisées
(chaque LLM note les autres)

Durée

Environ 45 minutes
par run complet

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation
- 6 Utilisation et perspectives
- 7 Conclusion

Les 7 LLM sélectionnés

Nom	Fournisseur	Modèle
Claude	Anthropic	claude-3-haiku
GPT	OpenAI	gpt-4o-mini
Gemini	Google	gemini-2.5-flash
Gemma 3	Google	gemma-3-27b-it
Qwen	Alibaba	qwen3-32b
Command R+	Cohere	command-a
Llama 3.3	Meta	llama-3.3-70b

Critère de sélection

Chaque modèle doit être fiable dans **les deux rôles** : répondant *et* juge. 4 modèles ont été écartés pour instabilité.

Couverture du marché

6 fournisseurs différents (Anthropic, OpenAI, Google, Alibaba, Cohere, Meta) pour une vue représentative.

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée**
- 5 Résultats et automatisation
- 6 Utilisation et perspectives
- 7 Conclusion

Étape 1 Les questions métier

10 questions spécifiques à l'assurance vie luxembourgeoise

- ❶ Libre Prestation de Services (LPS)
- ❷ Fonds Interne Dédié (FID) et FAS
- ❸ Triangle de Sécurité luxembourgeois
- ❹ Fiscalité transfrontalière
- ❺ Solvabilité II et SCR
- ❻ Unités de Compte
- ❼ Gestion et arbitrage
- ❽ Succession et transmission
- ❾ Clientèle High Net Worth
- ❿ Norme IFRS 17


Modulable

Ces questions peuvent être modifiées à tout moment pour adapter le benchmark aux besoins de l'équipe.

Étape 2 Collecte des réponses via OpenRouter

OpenRouter : une passerelle unique vers tous les LLM

Au lieu d'avoir une clé API par fournisseur (Anthropic, OpenAI, Google...), on utilise **une seule clé OpenRouter** qui donne accès à tous les modèles simultanément.



Étape 3 Le jury en aveugle

Comment ça fonctionne

- 1 Les réponses des 7 LLM sont **anonymisées**
Claude → "A", GPT → "B"...
- 2 Chaque LLM reçoit les 7 réponses anonymes et **attribue une note** sur 8 critères
- 3 Un LLM peut évaluer sa propre réponse **sans le savoir**
- 4 À la fin, on lève l'anonymat et on calcule les scores finaux

Pourquoi en aveugle ?

Pour éviter tout biais. Si un LLM savait quelle réponse lui appartient, il pourrait se favoriser ou défavoriser un concurrent. L'anonymisation garantit une évaluation neutre.

Résultat

70 évaluations croisées par run
(7 juges × 10 questions)

Étape 4 Calcul des scores pondérés

Critère	Poids
Exactitude technique	20 %
Vocabulaire assurance	20 %
Pertinence réglementaire	15 %
Complétude	15 %
Clarté et lisibilité	10 %
Absence d'hallucinations	10 %
Applicabilité pratique	5 %
Gestion de l'incertitude	5 %

Formule

Chaque réponse est notée de 0 à 10 sur les 8 critères par chacun des 7 juges. Le score final est la **moyenne pondérée** de toutes les notes reçues.

Note importante

Ces pondérations sont une **proposition initiale**. Elles peuvent être ajustées par l'équipe métier selon les priorités de Wealins.

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation**
- 6 Utilisation et perspectives
- 7 Conclusion

Résultats Dernier run (Juin 2026)

Rang	LLM	Score /10	Intervalle (± 0.3)
1	Command R+	8.08	7.78 – 8.38
2	Gemini	7.88	7.58 – 8.18
3	Gemma 3	7.66	7.36 – 7.96
4	Claude	7.58	7.28 – 7.88
5	GPT	7.42	7.12 – 7.72
6	Qwen	7.40	7.10 – 7.70
7	Llama 3.3	7.12	6.82 – 7.42

Observation

Scores globalement élevés et proches (7.1 – 8.1). Tous les modèles testés maîtrisent bien le domaine. L'intervalle ± 0.3 reflète la variabilité naturelle des LLM d'un run à l'autre.

Les notifications email

Deux types de notifications automatiques

Email 1 Nouvelle version détectée

Envoyé **avant le run** quand le système détecte qu'une nouvelle version d'un LLM est disponible sur le marché.

Exemple : "Gemini 3.5 vient de sortir, un nouveau run va être lancé."

Email 2 Résultats disponibles

Envoyé **après le run** avec le classement final des 7 LLM et le lien vers le dashboard.

Exemple : "Run terminé Command R+ arrive en tête avec 8.08/10."

Zéro action manuelle

Les emails sont envoyés automatiquement par le système. Le destinataire reçoit l'information sans avoir à surveiller quoi que ce soit.

Automatisation complète

Ce qui se passe automatiquement

- 1 **Détection** des nouvelles versions de LLM
- 2 **Décision** : run nécessaire ou pas ?
- 3 **Exécution** du benchmark (~45 min)
- 4 **Notification** par email
- 5 **Sauvegarde** des résultats sur GitHub
- 6 **Mise à jour** du dashboard en ligne

Déclenchement

Automatique : tous les lundis à 6h
Le système décide ensuite si un run est vraiment nécessaire.

Manuel : un clic sur GitHub Actions suffit pour forcer un run à tout moment.

Dashboard public

Accessible depuis n'importe quel navigateur, sans installation.
Mis à jour automatiquement après chaque run.

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation
- 6 Utilisation et perspectives**
- 7 Conclusion

Comment l'utiliser au quotidien

Consulter les résultats

Ouvrir le lien dashboard dans un navigateur. Aucune installation. Mis à jour automatiquement.

→ **Accessible à toute l'équipe**

Adapter le benchmark

Modifier les questions, les critères, ou ajouter de nouveaux LLM dans le code.

→ **Personnalisable selon les besoins**

Lancer un run manuellement

Aller sur GitHub → onglet Actions → cliquer *Run workflow*.

→ **Résultats en ~45 min**

À venir

Script d'installation en un double-clic pour lancer le projet sur n'importe quel PC du bureau sans toucher au code.

Plan

- 1 Contexte et problématique
- 2 La solution : benchmark automatisé
- 3 Les 7 modèles testés
- 4 Méthodologie détaillée
- 5 Résultats et automatisation
- 6 Utilisation et perspectives
- 7 Conclusion**

Conclusion

Ce que le projet apporte à Wealins

Un outil de veille LLM **automatisé, objectif et spécifique** au domaine de l'assurance vie luxembourgeoise. Zéro intervention manuelle après configuration initiale.

Points forts

Benchmark sur nos propres questions métier.

Jury en aveugle → résultats objectifs.

Historique d'évolution dans le temps.

Dashboard accessible sans installation.

Notifications email automatiques.

Prochaines étapes

Validation des critères par l'équipe métier.

Intégration de nouveaux LLM au fil des sorties.

Script d'installation locale simplifié.

Extension à d'autres domaines métier si besoin.

Merci pour votre attention.

Questions ?